

SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

SEMINAR

Suparnički generativni modeli za prevođenje slika

Krešimir Vukić

Voditelj: *prof. dr. sc. Siniša Šegvić*

Zagreb, svibanj 2018.

SADRŽAJ

1. Uvod	1
2. Duboke mreže	2
2.1. Konvolucija	2
2.2. Primjer konvolucijske mreže	3
3. Generativno modeliranje	4
3.1. Generativni naspram diskriminativnih algoritama	4
3.2. Suparnički modeli	5
3.3. Rad generativnih suparničkih modela	5
3.4. GAN-ovi naspram autoenkodera	6
4. Uvjetne generativne mreže	8
4.1. Generalizacija problema prevođenja slike	8
4.2. Pristup prevođenju slike	9
4.3. Primjena	9
5. Translacija bez uparenih primjera za učenje	10
5.1. Kružni GAN-ovi	10
5.1.1. Prednosti	10
5.1.2. Rad CycleGAN-a	10
5.2. Multimodalna translacija (MUNIT)	10
6. Prijenos stila	12
6.1. Očuvanje strukture	12
6.2. Lokalizacija stila i očuvanje konteksta	12
7. Zaključak	13
8. Literatura	14

1. Uvod

Razvojem tehnika namijenjenih identifikaciji i analizi slika te rapidnim razvojem neuronskih mreža, logični sljedeći korak unutar područja računalnog vida bio je osmišljavanje algoritama kojima bi se te tehnologije proširile na reprodukciju naučenih vizualnih sadržaja. Prijenos stilova, rekonstrukcija fotografije, generiranje tekstura ili simulacija interakcije molekula neke su od primjena dotičnog problema.

Najznačajniji pomak u tome području ostvarili su Goodfellow et al. 2014. g. [3] osmišljavanjem generativnih suparničkih modela. Tipičan cilj mreža baziranih na tom modelu je pronalazak funkcije preslikavanja iz prostora latentnih varijabli na željenu distribuciju, a kojom se teško rješivi matematički problemi svode na jednostavno zadavanje željenih ulaza rezultantne funkcije.

Dobivena distribucija, osim za generiranje novih primjera, primjenjiva je i na rješavanje prvotno navedenih problema identifikacije značajki na postojećim slikama. Ta fleksibilnost čini ovaj algoritam izuzetno popularnim za istraživanje što je rezultiralo njegovim mnogobrojnim modifikacijama i poboljšanjima.

Ovim radom istražiti će se različita proširenja kojima se ti modeli prilagođavaju specifičnim problemima, njihove karakteristike i primjene.

2. Duboke mreže

Posljednjih nekoliko godina, duboko učenje u potpunosti je zamijenilo klasične pristupe rješavanja problema na području umjetne inteligencije. Tu popularnost ostvarilo je zahvaljujući prednosti koju ima naspram klasičnih pristupa, a koja je ponajviše očita u radu s velikim količinama podataka.

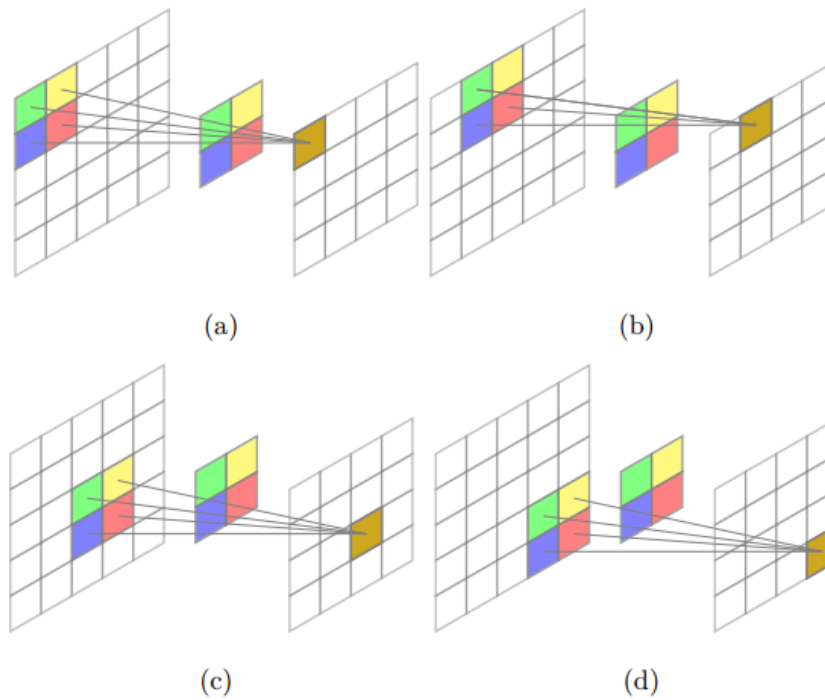
Dok je starije algoritme strojnog učenja potrebno modificirati ručnom identifikacijom značajki kako bi se primijenili na nove skupove podataka, dubokim mrežama dovoljno je predstaviti te podatke, a one na njih samostalno odluče koje su značajke bitne. Uz trendove računarstva koji idu prema ubrzanom gomilanju svih dostupnih informacija, njihova prednost će samo rasti.

Slojevit pristupu rastavljanja podataka na jednostavnije građevne jedinice čini ih posebice pogodnima za rad s problemima hijerarhijske prirode poput slika.

2.1. Konvolucija

Pri radu sa slikama, konvolucijske mreže su jedna od najznačajnijih podvrsta dubokih mreža. Osmišljene s ciljem dohvata lokalnih relacija među podacima, rješavaju problem nepoželjnog utjecaja pozadine i lokacije značajke unutar slike.


Ideja konvolucije je da se kao ulaz u neurone sljedećeg sloja dovedu isključivo okolne vrijednosti neurona s prethodnog [Slika 3.1]. To se odvija tako da se unaprijed definirano kvadratno područje(filter) pomiče (konvoluiru) po ulaznim podacima pri čemu množimo vrijednosti filtera s pripadnim ulaznim vrijednostima. Upravo taj filter je zadužen za identifikaciju određene značajke.



Slika 2.1: Proces konvolucije

2.2. Primjer konvolucijske mreže

Nizanjem konvolucijskih slojeva dobivamo arhitekturu u kojoj se odgovornost filtera raspoređuje tako da je svaki sloj zadužen za jednostavniji potproblem sljedećeg sloja. Prvi slojevi uče atome poput linija, boje ili orijentacije čijim kombiniranjem je moguće raspoznati sve složenije geometrijske oblike. Na slici 2.2 prikazana je duboka neuronska mreža s 5 konvolucijskih slojeva među kojima se odvija sažimanje maksimalnom vrijednošću te dva sloja potpune povezanosti.



Slika 2.2: Primjer duboke neuronske mreže

3. Generativno modeliranje

3.1. Generativni naspram diskriminativnih algoritama

Algoritme za učenje dijelimo na dvije temeljne skupine – diskriminativne i generativne:

- Diskriminativni modeli baziraju se na modeliranju isključivo pomoću ulaznih varijabli (X) koje direktno mapiraju na ciljne vrijednosti (Y) i time uče uvjetnu vjerojatnost $p(Y | X)$. Pošto se fokusiraju samo na mapiranje viđenih značajki u klase, ne stvaraju puno pretpostavki o podložnoj distribuciji, ali su vrlo ovisni o kvalitetnim podacima.
- Generativni modeli rješavaju inverzan problem – kako dobiti neku značajku X kada znamo kojoj klasi Y pripada, tj. pokušavaju naučiti distribuciju pojedinih klasa $p(X | Y)$.

Drugim riječima, dok diskriminativni modeli pokušavaju pronaći granicu između klasa, generativni modeliraju distribucije pojedinih klasa na temelju kojih mogu uzorkovati nove primjere.

3.2. Suparnički modeli

Iako je očito da su generativni algoritmi svestranije naravi od diskriminativnih, u praksi se pokazalo kako diskriminativni modeli postižu bolje rezultate od generativnih. Sposobnost generalizacije dolazi s neizbježnim povećanjem složenosti koja proizlazi iz toga što se pronalazak ciljne distribucije u dubokim hijerarhijskim podacima sastoji od rješavanja problema koje matematički nije moguće izvesti [3]. Približna rješenja dobivena su uvođenjem mnogobrojnih aproksimacija, no nažalost, posljedica toga je da optimum dobivenog modela nikad neće biti dobar kao što bi bio onaj s pravim rješenjem.

Alternativni pristup ponuđen je u obliku suparničkih modela – probleme kojima ljudi ne mogu pronaći rješenje, kroz dovoljno velik broj iteracija, moguće je naučiti pomoću dva modela koji se natječu u traženju čim bolje njegove aproksimacije dok ne pogode pravo rješenje. Ovisno o implementaciji, mreža takve arhitekture u stanju je izvesti distribuciju širokog spektra podataka: slika, govor, muzike, pa čak i pisanih zapisa.

3.3. Rad generativnih suparničkih modela

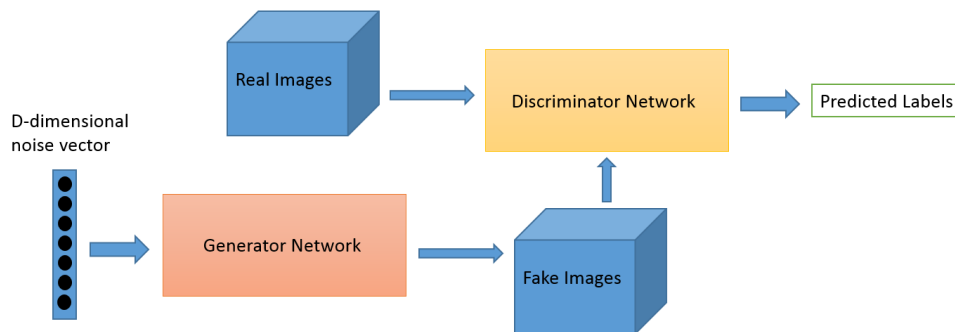
Ideja generativnih suparničkih modela bazirana je na učenje mreža kroz mini-max igru – umjesto izravnog rješavanja optimizacijskog problema, GAN sadrži funkciju kojoj mreže paralelno podešavaju ulaze dok ne dođu do stabilne točke u odnosu na maksimum jedne, a minimum strategije druge mreže.

Pola mreže (generator G) bavi se stvaranjem novih podataka iz neke jednostavne distribucije Z s ciljem da stvoreni podaci budu čim sličniji stvarnim.

Paralelno s njegovim radom, druga polovica (diskriminator D) pokušava evaluirati koliko su uzorci $G(Z)$ slični stvarnim podacima Y . Drugim riječima, dok G pokušava minimizirati izlaz $D - a$, D ga pokušava maksimizirati.

Koraci rada GAN-a:

1. Generator G iz nasumičnih brojeva (šum) Z stvara sliku $G(Z)$
2. Ta slika se zajedno sa uzorcima skupa stvarnih podataka Y dovodi na ulaz diskriminatora D
3. Diskriminator D određuje postotak vjerojatnosti da je slika $G(Z)$ prava




Slika 3.1: GAN [2]

3.4. GAN-ovi naspram autoenkodera

Uz GAN-ove, podjednako važna skupina generativnih modela su autoenkoderi. Ideja iza njihovog rada je da se sastoje od enkodera koji kompresira podatke u latentne varijable te dekodera koji iz tih varijabli ponovo generira ulaznu sliku. Naučenoj mreži možemo mijenjanjem latentnih varijabli vrlo precizno zadati kakve podatke želimo generirati. To im je ujedno i glavna prednost nad GAN-ovima koji generiraju dosta nasumične uzorke (što se može popraviti uz izmjene koje ću obraditi u sljedećim poglavljima).

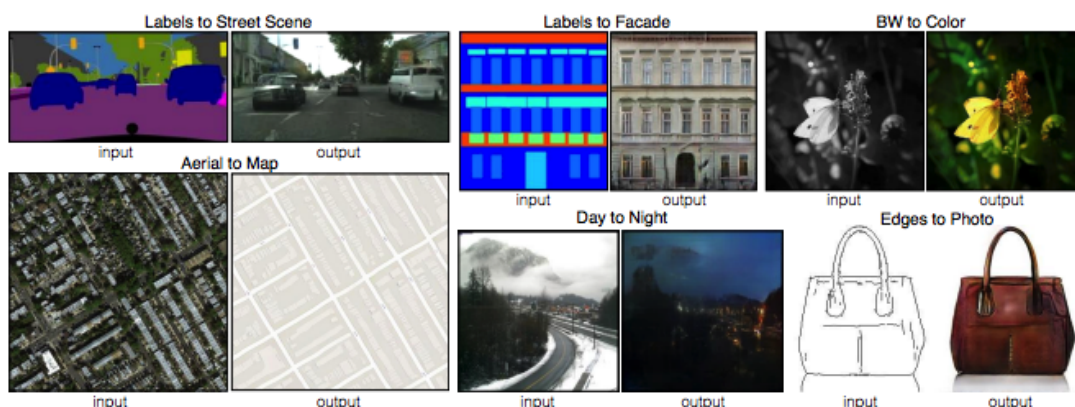
Negativna strana varijabilnih autoenkodera je što uzorci koje proizvode imaju dosta anomalija što na slikama rezultira time da više nalikuju na umjetničke slike nego realnu reprezentaciju. Zbog toga primarnu primjenu nalaze u industrijama poput video igara i kompresiji podataka. U istraživanju su i mreže koje ujedinjuju te dvije tehnologije trenirajući dekodera pomoću GAN-a [larsen2015autoencoding].



Slika 3.2: Kombinacija autoenkodera i GAN-a

4. Uvjetne generativne mreže

Kao što je spomenuto u prošlom poglavlju, jedna od većih mana generativnih suparničkih mreža je da generiraju poprilično nasumične uzorke. Pošto većina problema u praksi zahtijeva kontrolu nad tim procesom, jedno od najranijih proširenja GAN-ova vezano je upravo uz kontrolu generiranja podataka. Postavljanjem uvjeta na ulazu generativnog modela, moguće je usmjeriti generativni proces. Vrste uvjeta mogu biti raznolike: oznake klasa, skice, dubinske mape pa čak i cijele slike.



Slika 4.1: Primjeri uvjetovane generacije

4.1. Generalizacija problema prevođenja slike

Isola et al. [6] predložili su uvjetne generativne mreže kao generalno rješenje problema prevođenja slike. Svojtvene su po učenju ne samo funkcije prijenosa između slika već i funkcije gubitka nad kojom se ona trenira. Dok se u drugim modelima ona ručno zadaje, pristup u kojem se ona uči omogućuje generalizaciju nad setovima problema koji bi u suprotnom zahtijevali vrlo drugačije formulacije gubitka.

4.2. Pristup prevođenju slike

Analogno prevođenju teksta u drugi jezik zadržavajući određeni kontekst, prevođenje slike odnosi se na translaciju scene u drugačiju reprezentaciju. To se odnosi na mnogobrojne probleme za koje postoje zasebne metode rješavanja poput izmjene pozadine, lica ili promjene boje. No, u srži svih njih može se prepoznati jedinstven problem: naći funkciju preslikavanja piksela u piksel. Tijekom učenja, lošim definiranjem te funkcije, nikad nećemo dobiti realistične rezultate. GANovi pristupaju tome tako da odbacuju sva rješenja koja se mogu razlikovati od stvarnosti generirajući slike y iz nasumičnog šuma z : $G : z \rightarrow y$. Poboljšanje nad tom metodom dobivamo uz uvjetovanje ulaznih podataka, tj. uz dodavanja uvjeta na šum da mora sličiti stvarnoj distribuciji. To se postiže dodavanjem slike x slične željenoj na ulaz sustava $G : x, z \rightarrow y$ [6].

4.3. Primjena

Neke od mogućnosti uvjetnih GAN-ova su sinteza fotorealističnih slika iz skica, generiranje objekata na temelju njihovih obruba te bojanje crno bijelih fotografija.

5. Translacija bez uparenih primjera za učenje

5.1. Kružni GAN-ovi

5.1.1. Prednosti

Većina postojećih algoritama korištenih u računalnom vidu ovisi o postojanju velikih podatkovnih setova označenih parova slika. No, za mnoge probleme takvi podatci nisu dostupni, a u takvim situacijama primjenu nalaze kružni GAN-ovi.

5.1.2. Rad CycleGAN-a

Temelj njihovog rada je uz da uz učenje funkcije $G : X \rightarrow Y$, istovremeno uč njen inverz $F : Y \rightarrow X$ pomoću gubitka cikličke dosljednosti: $F(G(X)) \approx X$ i obrnuto.

5.2. Multimodalna translacija (MUNIT)

Poveća mana spomenutih načina translacije je manjak raznolikosti u transliranim izlazima. One ne uzimaju u obzir da je uvjetna distribucija preslikavanja slika između dvije domene inherentno multimodalna [5] što kao posljedicu ima da pri generiranju vrlo teško stvaraju vidljivo različite uzorke. MUNIT model pretpostavlja da se reprezentacija slike može rastaviti na značajke koje su domenski invarijantne te na one koje sadrže domenski specifična svojstva. Zatim se pri generiranju jednostavno domenski invarijantne značajke kombiniraju s nasumičnim stilskim kodom uzorkovanim s ciljne domene.

Pri podjeli reprezentacija sadržaja i stila, sadržaj se odnosi na prostornu strukturu dok je stil ograničen na rendering te strukture.

6. Prijenos stila

Cilj prijenosa stila je modificiranje stilističke perspektive slike uz očuvanje sadržaja. Generalna podjela metoda ovog procesa dijeli ih na prijenos na temelju primjera te na prijenos zajedničkog stila neke kolekcije. Dok se klasični pristupi baziraju na prvoj skupini, neuronske mreže bolje rezultate postižu na drugoj.

6.1. Očuvanje strukture

Postojeće metode ograničene su izborom stilova koje mogu prenijeti te u realističnosti dobivenih rezultata. Pokušaji prijenosa stila koji mijenjaju vrijednost piksela unose sitne izmjene u linijama i teksturama što na rezultatnom sadržaju stvara dojam crteža, a gubi se realističnost fotografije. Uvjet koji se zbog toga postavlja na rad mreže je da može unositi izmjene isključivo na prostoru boja.

6.2. Lokalizacija stila i očuvanje konteksta

[8] Postoji još jedan faktor koji povećava kompleksnost cijelog procesa, a to je da se ciljano ponašanje prijenosa stila drži konteksta izmjene. Na primjer, ako se na fotografiji nalaze livada i oblaci, modifikacije na livadi moraju biti povezane sa stilom livade na referentnoj slici, a ne da povuku stil s oblaka.

7. Zaključak

Generativni modeli tema su mnogobrojnih istraživanja i vrlo obećavajuća metoda učenja 'prirodnih' značajki podataka. Uz napretke koji se redovno postižu u njihovom unaprjeđenju, velika je vjerojatnost da će ubrzo biti u stanju generirati uzorke nerazlučive od stvarnosti. Time primjenu pronalaze u područjima poput stvaranja virtualnih svjetova bez ljudske intervencije, izvršavanja modifikacija nad slikama pomoću jednostavnog govora, regeneriranju oštećenih podataka ili stvaranju novih za buduća istraživanja.

... Uvjetnim suparničkim mrežama pokazano je da osim što više nije potrebno ručno izvoditi funkcije preslikavanja, zadovoljavajuće rezultate možemo dobiti i ako dubokoj mreži prepustimo da sama nauči funkciju gubitka. To je velik korak prema široj adaptaciji ove tehnologije upravo zato što uklanja potrebu za inženjerom i omogućava ljudima poput umjetnika i mladih znanstvenika da ju koriste samostalno. ...

8. Literatura

- [1] Amjad Almahairi, Sai Rajeswar, Alessandro Sordoni, Philip Bachman, i Aaron Courville. Augmented cyclegan: Learning many-to-many mappings from unpaired data. *arXiv preprint arXiv:1802.10151*, 2018.
- [2] Ian Goodfellow. Nips 2016 tutorial: Generative adversarial networks. *arXiv preprint arXiv:1701.00160*, 2016.
- [3] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, i Yoshua Bengio. Generative adversarial nets. U *Advances in neural information processing systems*, stranice 2672–2680, 2014.
- [4] Ian Goodfellow, Yoshua Bengio, i Aaron Courville. *Deep Learning*. MIT Press, 2016. <http://www.deeplearningbook.org>.
- [5] Xun Huang, Ming-Yu Liu, Serge Belongie, i Jan Kautz. Multimodal unsupervised image-to-image translation. *arXiv preprint arXiv:1804.04732*, 2018.
- [6] Phillip Isola, Jun-Yan Zhu, Tinghui Zhou, i Alexei A Efros. Image-to-image translation with conditional adversarial networks. *arXiv preprint*, 2017.
- [7] Anders Boesen Lindbo Larsen, Søren Kaae Sønderby, Hugo Larochelle, i Ole Winther. Autoencoding beyond pixels using a learned similarity metric. *arXiv preprint arXiv:1512.09300*, 2015.
- [8] Fujun Luan, Sylvain Paris, Eli Shechtman, i Kavita Bala. Deep photo style transfer. *CoRR, abs/1703.07511*, 2017.
- [9] Mehdi Mirza i Simon Osindero. Conditional generative adversarial nets. *arXiv preprint arXiv:1411.1784*, 2014.

- [10] Jun-Yan Zhu, Taesung Park, Phillip Isola, i Alexei A Efros. Unpaired image-to-image translation using cycle-consistent adversarial networks. *arXiv pre-print arXiv:1703.10593*, 2017.

Suparnički generativni modeli za prevođenje slika

Sažetak

Mnogi problemi u procesiranju slika odnose se na translaciju ulazne slike u željenu izlaznu. Većina današnjih arhitektura bazira se na generativnim suparničkim mrežama, nad kojima su osmišljena mnoga proširenja kako bi se prilagodila specifičnim problemima. Uvjetnim generativnim mrežama nije potrebno definirati funkciju gubitka jer ju mogu same naučiti, kružne generativne mreže sposobne su učenju translacije ne samo ulaznih u izlazne primjere nego i u drugom smjeru, a ograničavanjem mreže na translaciju unutar prostora boja obavljat će prijenos stila bez distorzije sadržaja slike. Ovim radom usporedit će različite arhitekture, njihove karakteristike i primjene na problemima translacije slike u sliku.

Ključne riječi: image-to-image generation, style transfer, GANs, CycleGANs

Image to image generation using CycleGANs

Abstract

Keywords: image-to-image generation, style transfer, GANs, CycleGANs