

SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

SEMINAR

Suparnički generativni modeli za prevođenje slika

Krešimir Vukić

Voditelj: *prof. dr. sc. Siniša Šegvić*

Zagreb, travanj 2018.

SADRŽAJ

1. Uvod	1
2. Duboke mreže	2
2.1. Konvolucija	2
2.2. Primjer konvolucijske mreže	3
3. Generativni suparnički modeli (GAN-ovi)	4
3.1. Generativni naspram diskriminativnih algoritama	4
3.2. Suparnički modeli	4
3.3. Rad GAN-a	5
4. Uvjetne generativne mreže	6
4.1. Generalizacija problema prevođenja slike	6
4.2. Pristup prevođenju slike	6
4.3. Primjena	6
5. Translacija bez uparenih primjera za učenje pomoću kružnih GAN-ova	7
5.1. Prednosti	7
5.2. Rad CycleGAN-a	7
5.3. Primjena	7
6. Prijenos stila	8
6.1. Očuvanje strukture	8
6.2. Lokalizacija stila i očuvanje konteksta	8
7. Zaključak	9
8. Literatura	10

1. Uvod

Generiranje slika na temelju skice, prijenos stilova i rekonstrukcija fotografije samo su neki od problema računalnog vida. Pri njihovom rješavanju uglavnom želimo naučiti funkciju mapiranja između parova slika koju zatim koristimo za efikasnu identifikaciju značajki ili po potrebi, njihovo generiranje.

Među najkorištenijim i najuspješnijim arhitekturama današnjice nalaze se generativni suparnički modeli. Ovim radom istražiti će se različita proširenja kojima se ti modeli prilagođavaju specifičnim problemima, njihove karakteristike i primjene.

2. Duboke mreže

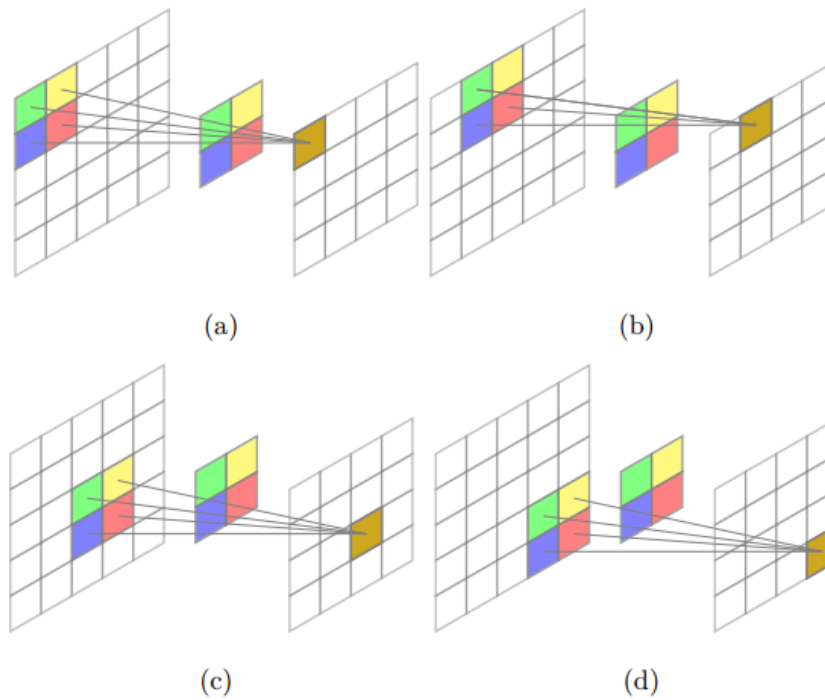
Duboke neuronske mreže zadnjih godina izuzetno su popularne u rješavanju klasifikacijskih problema i pronalaženju uzoraka. Tome je zaslužna prednost koju imaju naspram klasičnih pristupa, a koja se očituje u vidu mogućnosti da samostalno pronalaze bitne značajke u podacima te na temelju njih i tražena rješenja.

Slojevit pristupu rastavljanja podataka na jednostavnije građevne jedinice čini ih posebice pogodnima za radu sa problemima hijerarhijske prirode poput slika.

2.1. Konvolucija

Konvolucijske mreže osmišljene su s ciljem dohvata lokalnih relacija među podacima koje se posebice očituju pri radu sa slikama. Naime, ukoliko želimo analizirati malenu značajku na slici, nepoželjno je da njena pozadina ili lokacija unutar slike utječe na nju samu.


Ideja konvolucije je da se kao ulaz u neurone sljedećeg sloja dovede više vrijednosti s prethodnog što je prikazano slikom 2.1. To se odvija tako da se unaprijed definiran kvadrat pomiče (konvoluirá) po ulaznim podacima i tako određuje mapiranje na sljedeći sloj. Rezultat tog procesa je da pridodajemo veću važnost pikselima u neposrednoj okolini istraživanog područja.



Slika 2.1: Proces konvolucije

2.2. Primjer konvolucijske mreže

Nizanjem konvolucijskih slojeva dobivamo arhitekturu u kojoj je svaki sloj zadužen za jednostavniji potproblem sljedećeg sloja. Na slici 2.2 prikazana je duboka neuronska mreža s 5 konvolucijskih slojeva među kojima se odvija sažimanje maksimalnom vrijednošću te dva sloja potpune povezanosti.



Slika 2.2: Primjer duboke neuronske mreže

3. Generativni suparnički modeli (GAN-ovi)

3.1. Generativni naspram diskriminativnih algoritama

Dvije temeljne skupine kojima dijelimo algoritme za učenje su diskriminativni i generativni. Njihovi nazivi dolaze izravno iz vrste problema koji rješavaju:

Diskriminativni modeli direktno mapiraju ulazne varijable na ciljne vrijednosti i time uče uvjetnu vjerojatnost $p(Y|X)$. Dobiveni model svrstava podatke u ciljne klase s određenom vjerojatnošću.

Generativni modeli, kao što im i naziv govori, generativne su prirode. Problem koji rješavaju je kako dobiti X uz dani Y , tj. pokušavaju naučiti distribuciju pojedinih klasa $p(X | Y)$.

Drugim riječima, dok diskriminativni modeli pokušavaju pronaći granicu između klasa, generativni modeliraju distribucije pojedinih klasa na temelju kojih mogu uzorkovati nove primjere.

3.2. Suparnički modeli

Iz prethodnog poglavlja, očito je da su generativni algoritmi svestranije naravi od diskriminativnih, no to dolazi sa neizbježnim povećanjem složenosti. Pronalazak ciljne distribucije u dubokim hijerarhijskim podacima sastoji se na od aproksimiranja neizvodljivih problema[goodfellow2014generative]. Riješenje tog problema pronađeno je u suparničkim modelima. Oni su podvrsta dubokih mreža

čija arhitektura se bazira na dvije podmreže koje uče kroz međusobno natjecanje. Ovisno o implementaciji, mreža takve arhitekture u stanju je kopirati distribuciju širokog spektra podataka: slika, govora, muzike, pa čak i pisanih zapisa.

3.3. Rad GAN-a

Pola mreže bavi se stvaranjem novih podataka dok druga polovica pokušava evaluirati koliko su slični stvarnim podacima. Cijeli proces usporedljiv je s poslovima detektiva i kriminalca. Jedna strana u bavi se falsifikacijom dokaza, a druga analizom njihove autentičnosti.

Koraci rada GANa:

1. generator iz nasumičnih brojeva stvara sliku
2. ta slika se dovodi na ulaz diskriminatora uz skup stvarnih slika iz podatkovnog skupa
3. diskriminator određuje postotak vjerojatnosti da je slika prava

4. Uvjetne generativne mreže

4.1. Generalizacija problema prevođenja slike

Uvjetne generativne mreže pokazale su se kao generalno rješenje problema prevođenja slike [isola2017image]. Svojsvene su po učenju ne samo funkcije prijenosa između slika već i funkcije gubitka nad kojom se ona trenira. Dok se u drugim modelima ona ručno zadaje, pristup u kojem se ona uči omogućuje generalizaciju nad setovima problema koji bi u suprotnom zahtijevali vrlo drugačije formulacije gubitka.

4.2. Pristup prevođenju slike

Analogno prevođenju teksta u drugi jezik zadržavajući određeni kontekst, prevođenje slike odnosi se na translaciju scene u drugačiju reprezentaciju. To se odnosi na mnogobrojne probleme za koje postoje zasebne metode rješavanja poput izmjene pozadine, lica ili promjene boje. No, u srži svih njih može se prepoznati jedinstven problem: naći funkciju preslikavanja piksela u piksel. Tokom učenja, lošim definiranjem te funkcije, nikad nećemo dobiti realistične rezultate. GANovi pristupaju tome tako da odbacuju sva rješenja koja se mogu razlikovati od stvarnosti generirajući slike y iz nasumičnog šuma $z : G : z \rightarrow y$. Poboljšanje nad tom metodom dobivamo uz uvjetovanje ulaznih podataka, tj. uz dodavanja uvjeta na šum da mora sličiti stvarnoj distribuciji. To se postiže dodavanjem slike x slične željenoj na ulaz sustava $G : x, z \rightarrow y$ [isola2017image].

4.3. Primjena

Neke od mogućnosti uvjetnih GAN-ova su sinteza fotorealističnih slika iz skica, generiranje objekata na temelju njihovih obruba te bojanje crno bijelih fotografija.

5. Translacija bez uparenih primjera za učenje pomoću kružnih GAN-ova

5.1. Prednosti

Većina postojećih algoritama korištenih u računalnom vidu ovisi o postojanju velikih podatkovnih setova označenih parova slika. No, za mnoge probleme takvi podaci nisu dostupni, a u takvim situacijama primjenu nalaze kružni GANovi.

5.2. Rad CycleGAN-a

Temelj njihovog rada je uz da uz učenje funkcije $G : X \rightarrow Y$, istovremeno uče njen inverz $F : Y \rightarrow X$ pomoću gubitka cikličke dosljednosti: $F(G(X)) \approx X$ i obrnuto.

5.3. Primjena

6. Prijenos stila

6.1. Očuvanje strukture

Postojeće metode ograničene su izborom stilova koje mogu prenijeti te u realističnosti dobivenih rezultata. Pokušaji prijenosa stila koji mijenjaju vrijednost piksela unose sitne izmjene u linijama i teksturama što na resultantnom sadržaju stvara dojam crteža, a gubi se realističnost fotografije. Uvjet koji se zbog toga postavlja na rad mreže je da moguće unositi izmjene isključivo na prostoru boja.

6.2. Lokalizacija stila i očuvanje konteksta

[luan2017deep] Postoji još jedan faktor koji povećava kompleksnost cijelog procesa, a to je da se ciljano ponašanje prijenosa stila drži konteksta izmjene. Na primjer, ukoliko se na fotografiji nalaze livada i oblaci, modifikacije na livadi moraju biti povezane sa stilom livade na referentnoj slici, a ne da povuku stil sa oblaka.

7. Zaključak

... Uvjetnim suparničkim mrežama pokazano je da osim što više nije potrebno ručno izvoditi funkcije preslikavanja, zadovoljavajuće rezultate možemo dobiti i ako dubokoj mreži prepustimo da sama nauči funkciju gubitka. To je velik korak prema široj adaptaciji ove tehnologije upravo zato što uklanja potrebu za inženjerom i omogućava ljudima poput umjetnika i mladih znanstvenika da ju koriste samostalno. ...

8. Literatura

Ian Goodfellow, Yoshua Bengio, i Aaron Courville. *Deep Learning*. MIT Press, 2016. <http://www.deeplearningbook.org>.

Phillip Isola, Jun-Yan Zhu, Tinghui Zhou, i Alexei A Efros. Image-to-image translation with conditional adversarial networks. *arXiv preprint*, 2017.

Fujun Luan, Sylvain Paris, Eli Shechtman, i Kavita Bala. Deep photo style transfer. *CoRR*, *abs/1703.07511*, 2017.

Mehdi Mirza i Simon Osindero. Conditional generative adversarial nets. *arXiv preprint arXiv:1411.1784*, 2014.

Jun-Yan Zhu, Taesung Park, Phillip Isola, i Alexei A Efros. Unpaired image-to-image translation using cycle-consistent adversarial networks. *arXiv preprint arXiv:1703.10593*, 2017.

Suparnički generativni modeli za prevođenje slika

Sažetak

Mnogi problemi u procesiranju slika odnose se na translaciju ulazne slike u željenu izlaznu. Većina današnjih arhitektura bazira se na generativnim suparničkim mrežama, nad kojima su osmišljena mnoga proširenja kako bi se prilagodila specifičnim problemima. Uvjetnim generativnim mrežama nije potrebno definirati funkciju gubitka jer ju mogu same naučiti, kružne generativne mreže sposobne su učenju translacije ne samo ulaznih u izlazne primjere nego i u drugom smjeru, a ograničavanjem mreže na translaciju unutar prostora boja obavljat će prijenos stila bez distorzije sadržaja slike. Ovim radom usporedit će različite arhitekture, njihove karakteristike i primjene na problemima translacije slike u sliku.

Ključne riječi: image-to-image generation, style transfer, GANs, CycleGANs

Image to image generation using CycleGANs

Abstract

Keywords: image-to-image generation, style transfer, GANs, CycleGANs